高频因子是怎么回事——高频因子到底是怎么回事

Original 大空驴 流动性汗国 Liquidity Khanate 2024-03-21 19:15 新加坡

这是一篇对前文（指本人在2022年发布的同名文章，下简称前文）的呼应，是时隔一年多的反刍。

直到今天，本文的前身还持续受到关注和新的喜欢，也是我这么多文章中曝光量最高的，看来大家是真的很喜欢高频因子——无论是HFT的从业者还是非从业者。在最近的观察中，很多没有经受过严肃HFT训练的参与者容易不得其门而入，而在前文中没有给出详细的解答。故写下此文简单阐述HFT feature的基本特性，希望对不得入门的trader有所启发。

本文尽可能脱离本人的研究框架，谈论一些广泛的、低耦合的概念和知识，使得我想表达的概念能被有效地传达给读者。

从高频因子与低频因子的不同处出发

高频因子与低频因子的不同有很多，首先高频因子往往只需要广义的量价数据，比如成交和订单簿数据，而低频因子可能包括基本面等非标准化数据。除去依赖量价数据以外的因子不谈，如只比较基于量价数据的低频因子与高频因子，仍然有许多不同之处。

预测周期的不同

这是这两类因子最本质的不同了，一切都跟时间有关。低频因子的样本往往是有限的，如以一小时为周期的预测，对于股票市场来讲，一年可能只有一千个不重合的样本点，想要在这样有限的样本里做出可靠性强的统计工作，不得不依赖外部的业务逻辑，如果只靠量价数据本身，很容易拟合出假的阳性结果，很容易白高兴一场，不利于正常开展工作，对身心健康也有不利影响。

高频因子在巨大的样本量之下，容易规避market regime转变的问题，且如此大的样本量很容易得出统计上可靠的结论。这使得从人的角度来讲，统计指标往往比人脑能想到的逻辑更重要。一切为了corr服务，听起来像是很外行的实践，但对某些人来讲，确是不得不作出的、对现实困难的妥协。

预测目标的可靠程度不同

低频因子的预测是比较直接的，举个例子，某周期的价格和下个周期的价格做个除法、或是对数一下再减法，再减去交易成本就是真实的效用函数。这使得低频因子的结果是“更为直接的”，涨0.2%就是涨0.2%，至于怎么执行，也是简单的问题，有大量这种服务的提供商代替交易者去执行具体细节。

高频因子的预测是困难重重的，据我个人观察，高频因子预测目标的可靠程度是挡住新手的第一道大隔离墙。很多新手不知道应该怎么预测、预测什么，如果预测的目标是错误的，那无论怎么努力也达不到目标，看不到进展。下面一节中将阐述这种高频预测可靠程度低的成因。

高频预测可靠程度低的成因

我认为，高频预测和低频预测的差别根源是微观结构问题，主要是因市场特性等原因在内、导致价格序列不能被认为是鞅过程的问题。低频的预测可以近似认为价格是一个鞅过程，至少事前可以这样认为。

在高频的语境下，简单的预测目标不能起到作用，比如mid-price本身就是不可靠的，首先你在0.01%尺度上的预测使得你不能直接交易mid-price，因为你根本买不到mid-price的货，而对价单的冲击成本又远远超过信号的预测能力了，这使得预测本身完全不构成意义。

在我看来，这种无效的预测之所以成立，就是因为其无效。因为其无效，所以才能被轻松的预测到。

在没有手续费的市场中（虽然几乎没有这样的市场），价格本身可以认为是真实的。反之则可能要做关于手续费结构的修正。（如果读不懂不用焦虑，是正常的）

在有rebate的市场中，市场价格的有效性更是可疑，所有单子都集中在第一档上，难道大家都对这个价格情有独钟吗？不是的，只是有微观结构导致这个位置的价格被阻碍了移动。这导致高频率地观察价格会使得价格失真。

这是高频因子及预测困难的第一块大挡板。

高频因子在工程上的困难

高频的数据量真的很多，算一次需要巨大的内存和cpu算力，这里不展开详细讲了，总之工程上的困难比事前想象的要多得多，要有一套合适的基建帮助trader完成数据的清洗和落地工作，trader要自己想办法组织如此大的数据量计算。

这两部分都不是简单的工作，要做出一些妥协和取舍，不详细阐述，

高频因子的行业封闭性

所谓封闭性，很简单，就是人少，所以没办法产生一些工贼到处发布研究结果，低频的研究相对透明一些，至少技术指标的研究是百年老活了，最次也能看看双均线和布林带是如何组织的。而高频因子则是很晚进才出现的东西了，试想电子报价单出现才多少年呢?

包括我在前文中给出的部分因子示例，对于有些人来说，可能是第一次亲眼看到高频因子长什么样子。

尽管这样，我这里也不会给出新的高频因子了。

高频因子如何应用于策略逻辑

这是高频因子研究的第二块大挡板，高频因子输出一个或一大堆double vars，我该如何把这样的信息应用于交易呢？如何将广泛的高频因子输出成一个有意义的结果，是需要人发挥主观能动性的，本质上，对于Vec<f64>到f64的映射，是一个降维的过程，在这个过程（未必是唯一方法）中，信息量的丢失是必然的。

之所以说这是第二块大挡板，是因为工程问题总是可以解决的，小米加步枪也不是不能搓出有用的成果，只是效率太低，效率低不代表不能产生出有意义的结果。

第二块大挡板则是从方法和观念上限制了新手进一步前进。

第三块大挡板我个人认为在信号如何指导交易上，毕竟做了半天可能发现信号根本跑不赢手续费的一半，到那时候，你该怎么办呢？不过这些事限于篇幅，我也没法在这里讲，这是很复杂、需要个人自己思考的问题了。

这就是我认为高频研究困难的三块大挡板。

People who liked this content also liked

以交易为导向的学术论文阅读经验
流动性汗国 Liquidity Khanate

【广告】Remote!!! 区块链后端开发工程师
流动性汗国 Liquidity Khanate